

數2-2 數據分析

用中心、分散、標準化與線性模型，從資料回答可比較的問題

版本：學生版 | 核心+理解

範圍：114 學年度數學第二冊第 2 章；一維數據、百分位數、標準差、標準化、散布圖、相關係數與最小平方直線

內容校訂：2026-08-29

本章問題與能力

1. 一群資料的中心應如何用算術平均、加權平均或幾何平均描述？
2. 百分位數、四分位數、四分位距與標準差各保留了哪些資訊？
3. 資料經過伸縮與平移後，平均數、標準差及標準化數據如何改變？
4. 散布圖與相關係數如何描述兩個變量的線性關係？
5. 最小平方直線如何從資料建立預測模型，殘差又如何呈現模型誤差？

本章路徑：中心位置 → 排序位置 → 分散程度 → 標準化 → 線性相關 → 線性預測。

0. 本章實際用途：把大量觀測整理成可比較的資訊

一組原始數據常同時包含三種資訊：典型值落在哪裡、個體差異有多大，以及變量之間是否共同改變。平均數描述平衡位置，百分位數描述排序位置，標準差描述資料到平均數的典型距離。三者回答的問題不同，因此報告資料時通常要配合使用。

標準化把「高於平均多少」換成「高於平均幾個標準差」。不同科目的考試、不同單位的測量或不同族群的紀錄，便能放到共同尺度比較。醫療檢驗、品質管理與運動表現分析都會使用這個轉換。

兩個變量成對出現時，散布圖先顯示資料形狀，相關係數再濃縮線性方向與緊密程度。若散布點大致沿直線排列，最小平方法可建立預測式；預測仍需限制在資料涵蓋的情境與範圍內，並配合殘差判斷模型是否合適。

1. 資料的中心：算術、加權與幾何平均

1.1 算術平均數與平衡性質

一維數據只有一個觀測變量，例如一班學生的身高、同一城市每日最高溫或一批產品的重量。若資料為

$$x_1, x_2, \dots, x_n,$$

其算術平均數定義為

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}.$$

把每筆資料減去平均數，得到偏差 $x_i - \bar{x}$ 。由定義可推得

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n\bar{x} = 0.$$

因此平均數是帶號偏差的平衡點。低於平均的負偏差總量，恰好抵銷高於平均的正偏差總量。

算術平均數是帶號偏差的平衡點




圖 1 | 資料 2、4、9 的平均數為 5；三個帶號偏差相加為 0。

若只知道平均數與筆數，仍可還原總和：

$$\sum x_i = n\bar{x}.$$

這個關係常用於補遺失資料、合併兩組資料或更新平均數。

1.2 加權平均數

當各數值代表的次數或重要程度不同時，使用權數 $w_i > 0$ ：

$$\bar{x}_w = \frac{w_1 x_1 + w_2 x_2 + \cdots + w_n x_n}{w_1 + w_2 + \cdots + w_n}.$$

次數分配表中的次數就是權數。若資料值 $a_1, a_2, \dots, a_k$ 分別出現 $f_1, f_2, \dots, f_k$ 次，則總筆數為 $N = \sum f_i$ ，平均數為

$$\bar{x} = \frac{\sum f_i a_i}{N}.$$

1.3 幾何平均數與平均成長率

算術平均處理相加的量；連續成長則由倍率相乘。 n 個正數 $x_1, x_2, \dots, x_n$ 的幾何平均數為

$$G = \sqrt[n]{x_1 x_2 \cdots x_n}.$$

若連續 n 期的成長率為 $r_1, r_2, \dots, r_n$ ，每期倍率是 $1 + r_i$ 。等效的固定成長率 r 滿足

$$(1 + r)^n = (1 + r_1)(1 + r_2) \cdots (1 + r_n),$$

所以

$$r = \sqrt[n]{(1 + r_1)(1 + r_2) \cdots (1 + r_n)} - 1.$$

這個模型要求每期結束值成為下一期起始值，因此適用於資產、人口、產量等複合增減過程。

例 1 | 由分組人數計算總平均

甲班 24 人的平均成績為 72 分，乙班 16 人的平均成績為 82 分。求兩班合併後的平均成績。

先由「筆數乘平均」還原總分：

$$S_{\text{甲}} = 24 \times 72, \quad S_{\text{乙}} = 16 \times 82.$$

合併後共有 40 人，因此

$$\bar{x} = \frac{24 \times 72 + 16 \times 82}{40} = \frac{3040}{40} = 76 \text{ 分}.$$

兩班人數不同，直接平均 72 與 82 會把兩班誤當成同樣大小；以人數加權才對應全部 40 筆資料。

例 2 | 三年平均成長率

某項產量三年的成長率依序為 20%、-10%、25%。求等效的年平均成長率。

三年的總倍率為

$$1.20 \times 0.90 \times 1.25 = 1.35.$$

設等效年平均成長率為 r ，則

$$(1 + r)^3 = 1.35, \quad r = \sqrt[3]{1.35} - 1 \approx 0.1052.$$

所以等效年平均成長率約為 10.5%。驗算： $1.1052^3 \approx 1.35$ 。

練習 1A

1. 資料 6, 7, 8, 9, 10 的算術平均數為何？
2. 某課程的作業、期中考、期末考分數依序為 84、72、90，權重依序為 20%, 30%, 50%。求加權成績。
3. 顧客評價 1、2、3 分分別有 2、5、3 人。求平均評價。
4. 某數量連續兩年的倍率為 1.10 與 1.21。求等效的年平均成長率。
5. 六筆資料的平均數為 14，其中五筆為 8、11、13、17、19。求第六筆資料。

練習 1A 解析

1. $\bar{x} = (6 + 7 + 8 + 9 + 10)/5 = 8$ 。
2. $0.2(84) + 0.3(72) + 0.5(90) = 83.4$ 分。
3. 總人數為 10， $\bar{x} = (1 \times 2 + 2 \times 5 + 3 \times 3)/10 = 2.1$ 分。
4. $1 + r = \sqrt{1.10 \times 1.21} = \sqrt{1.331} \approx 1.1537$ ，故 $r \approx 15.4\%$ 。
5. 六筆總和為 $6 \times 14 = 84$ ，已知五筆和為 68，第六筆為 16。

2. 排序位置：百分位數與盒狀圖

2.1 第 m 百分位數

第 m 百分位數記作 P_m ，其中 $1 \leq m \leq 99$ 。它代表至少有 $m\%$ 的資料小於或等於 P_m ，同時至少有 $(100 - m)\%$ 的資料大於或等於 P_m 。

本章採用課本約定。先把 n 筆資料由小到大排成

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)},$$

再計算 $I = nm/100$ 。

- 若 I 不是整數，令 $M = \lceil I \rceil$ ，則 $P_m = x_{(M)}$ 。
- 若 I 是整數，則 $P_m = \frac{x_{(I)} + x_{(I+1)}}{2}$ 。

同一組資料若採用其他統計軟體的內插規則，數值可能略有差異；書面作答應先確認題目指定的定義。本章計算均依上列規則。

第 1、2、3 四分位數分別為

$$Q_1 = P_{25}, \quad Q_2 = P_{50}, \quad Q_3 = P_{75}.$$

Q_2 就是中位數。四分位距定義為

$$\text{IQR} = Q_3 - Q_1,$$

它描述中間 50% 資料占據的範圍，對極端值的反應通常小於全距。

百分位數與盒狀圖保留資料的位置資訊




圖 2 | 先排序再定位四分位數；盒狀圖依本章百分位數規則繪出五數摘要。

2.2 五數摘要與盒狀圖

盒狀圖用最小值、 Q_1 、中位數、 Q_3 、最大值五個數描述資料。盒子的左右端是 Q_1, Q_3 ，盒內線段是中位數，兩側線段延伸至最小值與最大值。

盒狀圖可以快速比較多組資料的中心、分散與偏斜情形。例如右側鬚明顯較長，表示較大的資料占據較寬範圍；中位數偏向盒子一端，也表示盒內兩半的分散程度不同。

例 3 | 依排序位置求百分位數

十筆資料已由小到大排列：

10, 13, 16, 18, 22, 24, 26, 28, 30, 33.

求 P_{35} 與 P_{60} 。

對 P_{35} ， $I = 10 \times 0.35 = 3.5$ 。3.5 不是整數，向上取到第 4 筆，所以 $P_{35} = 18$ 。

對 P_{60} ， $I = 10 \times 0.60 = 6$ 。6 是整數，取第 6、7 筆平均：

$$P_{60} = \frac{24 + 26}{2} = 25.$$

例 4 | 五數摘要與四分位距

資料為 2, 4, 5, 7, 9, 12, 14, 18。求五數摘要與四分位距。

資料已排序且 $n = 8$ 。

$$Q_1 = \frac{x_{(2)} + x_{(3)}}{2} = \frac{4+5}{2} = 4.5,$$

$$Q_2 = \frac{x_{(4)} + x_{(5)}}{2} = \frac{7+9}{2} = 8,$$

$$Q_3 = \frac{x_{(6)} + x_{(7)}}{2} = \frac{12+14}{2} = 13.$$

五數摘要為 (2, 4.5, 8, 13, 18)，四分位距為 $13 - 4.5 = 8.5$ 。

練習 2A

1. 九筆已排序資料為 3, 5, 6, 8, 10, 13, 15, 18, 21。求 P_{40} 。
2. 同一組九筆資料的 Q_1, Q_2, Q_3 為何？
3. 資料的五數摘要為 (12, 18, 24, 31, 45)。求全距與四分位距。
4. 甲組的中位數為 70、IQR 為 8；乙組的中位數為 66、IQR 為 20。比較中心與中間一半資料的分散。
5. 某成績的 $P_{88} = 13$ 級分。說明這個數值的排序意義。

練習 2A 解析

1. $I = 9(0.40) = 3.6$ ，取第 4 筆，故 $P_{40} = 8$ 。
2. P_{25} 的位置為 2.25，取第 3 筆得 $Q_1 = 6$ ； P_{50} 的位置為 4.5，取第 5 筆得 $Q_2 = 10$ ； P_{75} 的位置為 6.75，取第 7 筆得 $Q_3 = 15$ 。答案為 (6, 10, 15)。
3. 全距 = $45 - 12 = 33$ ；IQR = $31 - 18 = 13$ 。
4. 甲組中位數較高，且中間 50% 的資料較集中；乙組中心較低，中間 50% 占據的範圍較寬。
5. 至少有 88% 的成績小於或等於 13 級分，同時至少有 12% 的成績大於或等於 13 級分。

3. 分散程度、線性轉換與標準化

3.1 變異數與標準差

偏差的總和恆為 0，所以直接平均偏差無法描述分散程度。把偏差平方後再平均，得到變異數：

$$s_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

本章資料視為完整的一組，分母使用 n 。變異數的單位是原單位的平方；開平方後得到與原資料同單位的標準差：

$$s_x = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

展開平方可得到常用計算式：

$$\begin{aligned} s_x^2 &= \frac{1}{n} \sum (x_i^2 - 2x_i\bar{x} + \bar{x}^2) \\ &= \frac{1}{n} \sum x_i^2 - 2\bar{x}\left(\frac{1}{n} \sum x_i\right) + \bar{x}^2 \\ &= \frac{1}{n} \sum x_i^2 - \bar{x}^2. \end{aligned}$$




圖 3 | 兩組資料都有平均數 6；資料 B 到中心的距離較大，因此標準差較大。

3.2 資料的伸縮與平移

若每筆資料都經過相同轉換 $y_i = ax_i + b$ ，則

$$\bar{y} = a\bar{x} + b, \quad s_y = |a|s_x.$$

第一式由平均數的線性性質直接得到。第二式來自

$$y_i - \bar{y} = a(x_i - \bar{x}),$$

每個偏差都乘上 a ，平方平均後乘上 a^2 ，再開平方得到 $|a|$ 。加上常數 b 會把所有資料一起平移，彼此距離不變，所以標準差不受 b 影響。

平移改變中心；伸縮同時改變中心距離與標準差




圖 4 | 線性轉換的平移改變中心，伸縮改變資料間距。

3.3 標準化數據

當 $s_x > 0$ 時，第 i 筆資料的標準化數據或 z 分數為

$$z_i = \frac{x_i - \bar{x}}{s_x}.$$

z_i 的正負表示資料在平均數哪一側， $|z_i|$ 表示距離平均數幾個標準差。全部 z 分數的平均為 0、標準差為 1：

$$\bar{z} = \frac{1}{n} \sum \frac{x_i - \bar{x}}{s_x} = 0,$$

$$s_z^2 = \frac{1}{n} \sum \left(\frac{x_i - \bar{x}}{s_x} \right)^2 = 1.$$




圖 5 | z 分數把不同考試的原始分數轉成離各自平均數的標準差數。

例 5 | 由偏差平方計算標準差

資料為 2, 4, 4, 6, 9。平均數為 5，偏差平方和為

$$(-3)^2 + (-1)^2 + (-1)^2 + 1^2 + 4^2 = 28.$$

因此

$$s_x^2 = \frac{28}{5} = 5.6, \quad s_x = \sqrt{5.6} \approx 2.37.$$

平均數與原資料同單位，變異數使用平方單位，標準差回到原單位。

例 6 | 攝氏與華氏資料的統計量

一組攝氏溫度的平均為 18°C 、標準差為 4°C 。華氏溫度為 $F = 1.8C + 32$ 。求華氏資料的平均與標準差。

$$\bar{F} = 1.8(18) + 32 = 64.4^\circ\text{F},$$

$$s_F = |1.8| \times 4 = 7.2^\circ\text{F}.$$

轉換中的 32 只改變中心；倍率 1.8 同時放大中心差與資料間距。

例 7 | 比較不同考試中的相對表現

某生甲科 72 分，班平均 60 分、標準差 8 分；乙科 82 分，班平均 70 分、標準差 6 分。

$$z_{\text{甲}} = \frac{72 - 60}{8} = 1.5, \quad z_{\text{乙}} = \frac{82 - 70}{6} = 2.$$

乙科成績高於該科平均 2 個標準差，甲科高於平均 1.5 個標準差，因此乙科的相對位置較高。

練習 3A

1. 資料 1, 3, 5, 7 的平均數、變異數與標準差為何？
2. 一組資料平均為 50、標準差為 6。每筆都加 12 後，新平均與新標準差為何？
3. 承上題，若再把新資料全部乘以 -2，平均與標準差為何？
4. 某測量值為 84，該組平均為 72、標準差為 8。求 z 分數並解釋。
5. 一組標準差為 0 的資料具有什麼共同特徵？
6. 兩組資料 A、B 的平均都是 20，標準差分別為 3 與 9。某筆資料在 A 中是 26，在 B 中是 32；比較兩筆資料的相對位置。

練習 3A 解析

1. $\bar{x} = 4$ ；偏差平方和 $= 9 + 1 + 1 + 9 = 20$ ，所以 $s^2 = 5$ 、 $s = \sqrt{5}$ 。
2. 平移 12：新平均 62，標準差仍為 6。
3. 乘以 -2：平均為 -124，標準差為 $|-2| \times 6 = 12$ 。
4. $z = (84 - 72)/8 = 1.5$ ，表示該值高於平均 1.5 個標準差。
5. 每筆資料都等於平均數，因此全部資料相同。
6. $z_A = (26 - 20)/3 = 2$ ， $z_B = (32 - 20)/9 = 4/3$ ；A 中的資料相對位置較高。

4. 二維數據：散布圖與相關係數

4.1 成對資料與散布圖

二維數據由成對觀測值

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

組成。每一對必須來自同一個觀測單位，例如同一位學生的讀書時間與成績、同一天的溫度與用電量。把各對資料畫成平面上的點，就得到散布圖。

散布圖先判讀方向、形狀、緊密程度與特殊點。方向記錄 x 增加時 y 大致增加或減少；形狀區分直線、曲線或分群；緊密程度比較點群離主要形狀的距離；特殊點包含離群值與對模型有高度影響的點。

相關係數只概括線性方向與緊密程度




圖 6 | 四種散布型態；相關係數概括線性訊號，散布圖保留資料形狀。

4.2 相關係數

設 x, y 的平均數與標準差分別為 $\bar{x}, s_x$ 與 $\bar{y}, s_y$ ，且 $s_x, s_y > 0$ 。皮爾森相關係數定義為

$$r = \frac{1}{n} \sum_{i=1}^n \frac{x_i - \bar{x}}{s_x} \frac{y_i - \bar{y}}{s_y} = \frac{\frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})}{s_x s_y}.$$

當一筆資料的 x, y 同時高於各自平均，或同時低於各自平均，兩個 z 分數乘積為正；一高一低時乘積為負。因此 r 的正負表示線性方向。

由柯西不等式

$$(\sum z_{x_i} z_{y_i})^2 \leq (\sum z_{x_i}^2)(\sum z_{y_i}^2) = n^2,$$

可得 $-1 \leq r \leq 1$ 。 $r = 1$ 表示所有點落在正斜率直線上， $r = -1$ 表示落在負斜率直線上。 $|r|$ 越接近 1，線性排列越緊密； r 接近 0 只表示線性訊號弱，散布圖仍可能呈現曲線或分群。

若 $X' = aX + b$ 、 $Y' = cY + d$ ，其中 $a, c \neq 0$ ，則

$$r_{X', Y'} = \text{sgn}(ac) r_{X, Y}.$$

平移不改變相關係數；正倍率保留方向，負倍率翻轉方向。

4.3 離群值與解釋範圍

相關係數會受少數遠離點群的資料影響。報告 r 前應先看散布圖，確認點的配對、形狀、範圍與特殊點。

散布圖能揭露單一資料點對相關係數的影響




圖 7 | 加入一個高影響點後，相關係數由接近 1 明顯下降。

相關反映共同變動，因果關係還需要時間順序、控制變因、機制與實驗或其他證據。例如冰品銷量與用電量可能同時隨氣溫上升，兩者的相關不等於其中一者造成另一者。

例 8 | 完全正線性相關

資料為 (1, 2), (2, 4), (3, 6), (4, 8)。每一點都滿足 $y = 2x$ ，標準化後有 $z_{y_i} = z_{x_i}$ ，所以

$$r = \frac{1}{n} \sum z_{x_i}^2 = 1.$$

直線斜率為 2，而相關係數為 1；相關係數沒有單位，也不等於原圖斜率。

例 9 | 由偏差表計算相關係數

四對資料為 (1, 4), (2, 1), (3, 3), (4, 2)。 x, y 的平均數都為 2.5，標準差都為 $\sqrt{1.25}$ 。偏差乘積和為

$$(-1.5)(1.5) + (-0.5)(-1.5) + (0.5)(0.5) + (1.5)(-0.5) = -2.$$

因此

$$r = \frac{(-2)/4}{\sqrt{1.25}\sqrt{1.25}} = \frac{-0.5}{1.25} = -0.4.$$

資料呈負線性方向；完整判讀仍需配合散布圖。

例 10 | 單位轉換對相關係數的影響

身高 H 以公分表示，體重為 W ，已知 $r_{H,W} = 0.72$ 。若改用英吋 $H' = H/2.54$ ，並定義指標 $K = 100 - W$ ，求 $r_{H',K}$ 。

H' 對 H 是正倍率轉換，保留方向； K 對 W 是負倍率加平移，翻轉方向。因此 $r_{H',K} = -0.72$ 。

練習 4A

1. 散布點由左下向右上形成狹長帶狀，相關係數的符號與大致大小如何？

2. 若所有資料滿足 $y = 7 - 3x$ 且 x 不全相同，求 r 。
3. 已知 $r_{X,Y} = -0.65$ 。求 $r_{2X+5, 4Y-1}$ 與 $r_{-X, 4Y-1}$ 。
4. 某資料的 $r = 0.03$ ，散布圖呈清楚的 U 形。應如何描述兩變量關係？
5. 一份資料把不同學生的身高與體重分別排序後再任意配對。這個散布圖能否代表原來的身高一體重關係？說明理由。
6. 廣告費與銷售額高度正相關。列出一項仍需檢查、才能支持「提高廣告費造成銷售增加」的證據。

練習 4A 解析

1. 符號為正，且 $|r|$ 接近 1；實際數值仍須由資料計算。
2. 全部點落在負斜率直線上，所以 $r = -1$ 。
3. 兩個正倍率保留方向，第一式為 -0.65 ；第一個倍率為負，第二式為 0.65 。
4. 兩變量的線性相關接近 0，但存在明顯非線性關係；U 形結構由散布圖提供。
5. 無法。二維資料的每一對觀測必須來自同一位學生，任意重配會改變共同變動資訊。
6. 可檢查隨機或合理控制下的實驗結果、廣告投入先於銷售改變的時間資料，並控制季節、價格與促銷等共同因素。任列一項且說明作用即可。

5. 最小平方直線與殘差

5.1 預測值與殘差

用直線 $\hat{y} = a + bx$ 預測 y 時，第 i 筆的預測值為 $\hat{y}_i = a + bx_i$ ，殘差為

$$e_i = y_i - \hat{y}_i.$$

殘差是散布點到直線的鉛直帶號距離。最小平方直線選擇 a, b ，使殘差平方和

$$SSE = \sum_{i=1}^n (y_i - a - bx_i)^2$$

達到最小。




圖 8 | 每一條綠色虛線是一個殘差；最小平方直線通過 $(\bar{x}, \bar{y})$ 。

5.2 迴歸係數的推導

固定 b 時，將 $y_i - a - bx_i = (y_i - bx_i) - a$ 視為一組數據到常數 a 的距離。平方和在 a 等於這組數據的平均時最小，因此

$$a = \bar{y} - b\bar{x}.$$

代回後，令 $u_i = x_i - \bar{x}$ 、 $v_i = y_i - \bar{y}$ ，則

$$\begin{aligned} \text{SSE} &= \sum (v_i - bu_i)^2 \\ &= \sum v_i^2 - 2b \sum u_i v_i + b^2 \sum u_i^2. \end{aligned}$$

這是以 b 為變數、開口向上的二次式。配方後最小值出現在

$$b = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = r \frac{s_y}{s_x}.$$

截距為 $a = \bar{y} - b\bar{x}$ ，所以最小平方直線必通過 $(\bar{x}, \bar{y})$ 。斜率 b 帶有 y 單位除以 x 單位，表示 x 每增加 1 單位時，模型預測的 y 平均改變量。

在標準化坐標中，迴歸式簡化為

$$\hat{z}_y = rz_x.$$

5.3 使用範圍與殘差判讀

線性預測適用於散布圖在觀測範圍內大致呈直線的資料。若殘差圖仍呈彎曲、漏斗狀或分群，代表直線尚未捕捉主要結構。遠離觀測範圍的外插會依賴未被資料驗證的趨勢，預測不確定性通常更高。

迴歸線預測的是群體中的典型 y ，個別觀測仍可能因未納入變量與隨機差異偏離直線。殘差的單位與 y 相同，正殘差表示實際值高於預測值。

例 11 | 建立最小平方直線

六對資料為 $(1, 2), (2, 3), (3, 5), (4, 4), (5, 7), (6, 8)$ 。計算得

$$\bar{x} = 3.5, \quad \bar{y} = \frac{29}{6},$$
$$\sum (x_i - \bar{x})^2 = \frac{35}{2}, \quad \sum (x_i - \bar{x})(y_i - \bar{y}) = \frac{41}{2}.$$

因此

$$b = \frac{41}{35}, \quad a = \frac{29}{6} - \frac{41}{35} \cdot \frac{7}{2} = \frac{11}{15}.$$

最小平方直線為

$$\hat{y} = \frac{11}{15} + \frac{41}{35}x \approx 0.733 + 1.171x.$$

用 $x = 7$ 預測得 $\hat{y} \approx 8.93$ 。這只比原資料最大 $x = 6$ 多 1，屬鄰近外插，仍應標示預測性質。

例 12 | 由摘要統計量寫出迴歸式

某資料有 $\bar{x} = 40, s_x = 5, \bar{y} = 70, s_y = 8, r = 0.75$ 。求以 x 預測 y 的最小平方直線，並預測 $x = 46$ 時的 y 。

$$b = r \frac{s_y}{s_x} = 0.75 \cdot \frac{8}{5} = 1.2.$$

用通過平均點的形式：

$$\hat{y} - 70 = 1.2(x - 40),$$

故 $\hat{y} = 22 + 1.2x$ 。代入 $x = 46$ 得 $\hat{y} = 77.2$ 。

例 13 | 用殘差平方和比較直線

資料為 $(1, 2), (2, 3), (3, 5)$ 。資料平均為 $\bar{x} = 2, \bar{y} = 10/3$ ，最小平方直線為

$$\hat{y} = \frac{1}{3} + \frac{3}{2}x.$$

三個殘差依序為 $1/6, -1/3, 1/6$ ，所以

$$SSE_{LS} = \frac{1}{36} + \frac{1}{9} + \frac{1}{36} = \frac{1}{6}.$$

對候選直線 $y = x + 1$ ，三個殘差為 0, 0, 1，所以 $SSE_{x+1} = 1$ 。 $1/6 < 1$ ，數值驗證最小平方直線的平方誤差較小。

練習 5A

1. 已知 $\bar{x} = 10, s_x = 2, \bar{y} = 30, s_y = 6, r = 0.5$ 。求以 x 預測 y 的迴歸式。
2. 承上題，當 $x = 14$ 時的預測值為何？
3. 某點的實際值為 42，模型預測值為 39.5。求殘差並說明正負。
4. 最小平方直線為 $\hat{y} = 5 - 0.8x$ 。把 x 增加 3 單位時，預測 y 改變多少？
5. 已知 $z_x = 1.5, r = -0.6$ 。求預測的 z_y 。
6. 一份資料的 x 範圍為 20 至 40，模型被拿來預測 $x = 100$ 。指出這項預測需要揭露的限制。

練習 5A 解析

1. $b = 0.5(6/2) = 1.5$ ，所以 $\hat{y} - 30 = 1.5(x - 10)$ ，即 $\hat{y} = 15 + 1.5x$ 。
2. $\hat{y} = 15 + 1.5(14) = 36$ 。
3. $e = 42 - 39.5 = 2.5$ ；正值表示實際值高於模型預測。
4. $\Delta\hat{y} = -0.8(3) = -2.4$ ，預測值下降 2.4 單位。
5. $\hat{z}_y = rz_x = (-0.6)(1.5) = -0.9$ 。
6. $x = 100$ 遠超出觀測範圍，屬遠距外插；資料沒有驗證直線趨勢在該處仍成立，預測不確定性較高。

6. 代表題與跨節整合題

基礎與核心題

1. 八筆資料的平均數為 15。加入一筆 24 後，新平均數為何？
2. 某投資兩年的報酬率依序為 44% 與 -19%。求等效年平均報酬率。
3. 十二筆由小到大排列的資料中，第 3、4 筆為 18、21，第 6、7 筆為 29、31，第 9、10 筆為 42、50。求 Q_1, Q_2, Q_3 。
4. 甲組資料的五數摘要為 (10, 18, 25, 31, 48)，乙組為 (8, 21, 24, 28, 40)。比較兩組中位數、IQR 與全距。
5. 資料 3, 3, 7, 7 的平均數與標準差為何？
6. 一組資料平均為 12、標準差為 5。新資料定義為 $Y = 20 - 3X$ 。求 Y 的平均與標準差。
7. 某生分數 76，群體平均 64、標準差 10。求 z 分數。
8. 已知 $r_{X,Y} = 0.84$ 。求 $r_{5-2X, 3Y+7}$ 。

推理與資料題

9. 某散布圖的點完整落在圓周上。說明為何僅報告 r 無法完整描述 X, Y 關係。
10. 五對資料的標準化數據乘積依序為 0.8, 1.1, -0.2, 0.4, 0.9。求相關係數。

11. 已知 $\bar{x} = 50, s_x = 10, \bar{y} = 120, s_y = 15, r = -0.8$ 。求以 x 預測 y 的最小平方直線。
12. 模型為 $\hat{y} = 18 + 2.4x$ 。觀測 $(x, y) = (5, 33)$ 的殘差為何？若另一點殘差為 -4 ，它在迴歸線哪一側？

跨節整合題

13. 某班原始成績平均 68、標準差 8。教師採用新分數 $Y = 1.25X + 5$ 。學生甲原始成績 84。求新分數的平均、標準差及甲的原始與新制 z 分數，並說明相對位置是否改變。
14. 八筆每日氣溫與用電量資料的摘要為 $\bar{x} = 28^\circ\text{C}, s_x = 2^\circ\text{C}, \bar{y} = 420 \text{ kWh}, s_y = 30 \text{ kWh}, r = 0.7$ 。求迴歸式，預測 30°C 的用電量，並說明把此式用於 45°C 的主要限制。
15. 某組十筆資料加入一筆遠離點群的資料後， x 平均由 20 變為 23。求新加入資料的 x 值。加入前 $r = 0.91$ ，加入後 $r = 0.28$ ；依這些資訊提出合理的資料檢查流程。
16. 兩地跑步成績以秒記錄。甲地平均 780 秒、標準差 60 秒；乙地平均 720 秒、標準差 40 秒。選手 A 在甲地跑 690 秒，選手 B 在乙地跑 660 秒。以 z 分數比較相對表現；再說明「時間越短越好」如何影響結論的語意。

7. 完整詳解

- 原八筆總和為 $8 \times 15 = 120$ 。加入 24 後總和 144、筆數 9，所以新平均為 16。
- 兩年總倍率為 $1.44 \times 0.81 = 1.1664$ 。設等效年平均報酬率為 r ，則 $1 + r = \sqrt[2]{1.1664} = 1.08$ ，因此 $r = 8\%$ 。
- $n = 12$ 。 Q_1 的位置為 3，取第 3、4 筆平均，得 $Q_1 = 19.5$ ； Q_2 的位置為 6，得 $Q_2 = 30$ ； Q_3 的位置為 9，得 $Q_3 = 46$ 。故 $(Q_1, Q_2, Q_3) = (19.5, 30, 46)$ 。
- 甲、乙中位數分別為 25、24，甲較高 1。IQR 分別為 $31 - 18 = 13$ 、 $28 - 21 = 7$ ，乙組中間一半較集中。全距分別為 $48 - 10 = 38$ 、 $40 - 8 = 32$ ，乙組整體範圍也較小。
- 平均數為 5。偏差為 $-2, -2, 2, 2$ ，所以 $s = \sqrt{(4 + 4 + 4 + 4)/4} = 2$ 。
- $\bar{Y} = 20 - 3(12) = -16$ ； $s_Y = |-3|(5) = 15$ 。負倍率翻轉資料次序，但標準差取距離大小。
- $z = (76 - 64)/10 = 1.2$ ，表示成績高於群體平均 1.2 個標準差。
- $5 - 2X$ 的倍率為負， $3Y + 7$ 的倍率為正，因此相關方向翻轉，大小不變： -0.84 。
- 圓周呈明顯的非線性封閉關係。同一個 x 可能對應上下兩個 y ，整體正、負偏差乘積可能互相抵銷，使 r 接近 0。應同時呈現散布圖並描述曲線結構。
- $r = (0.8 + 1.1 - 0.2 + 0.4 + 0.9)/5 = 3.0/5 = 0.6$ 。
- 斜率 $b = -0.8(15/10) = -1.2$ 。迴歸線通過 $(50, 120)$ ：

$$\hat{y} - 120 = -1.2(x - 50),$$

所以 $\hat{y} = 180 - 1.2x$ 。

12. $x = 5$ 時， $\hat{y} = 18 + 2.4(5) = 30$ ，殘差 $e = 33 - 30 = 3$ 。殘差 -4 表示實際值比預測值低 4，點位於迴歸線下方。

13. 新平均與標準差為

$$\bar{Y} = 1.25(68) + 5 = 90, \quad s_Y = 1.25(8) = 10.$$

甲的新分數為 $1.25(84) + 5 = 110$ 。兩種制度的 z 分數皆為 2：

$$z_X = \frac{84 - 68}{8} = 2, \quad z_Y = \frac{110 - 90}{10} = 2.$$

正倍率線性轉換保留標準化位置，因此相對位置不變。

14. 斜率 $b = 0.7(30/2) = 10.5 \text{ kWh/}^\circ\text{C}$ 。迴歸式為

$$\hat{y} - 420 = 10.5(x - 28),$$

即 $\hat{y} = 126 + 10.5x$ 。 $x = 30$ 時， $\hat{y} = 441 \text{ kWh}$ 。 45°C 遠離觀測範圍，線性趨勢是否持續缺乏資料支持；設備容量與用電行為也可能在極端高溫改變。

15. 原十筆總和為 $10(20) = 200$ 。加入後共 11 筆、總和 $11(23) = 253$ ，所以新資料的 x 值為 53。檢查流程可依序為：回查原始紀錄與單位、確認它是否屬於同一觀測族群、比較含與不含該點的散布圖與相關係數、說明保留或排除的資料理由。 r 的大幅下降顯示這一點具有高度影響。

16. 秒數的 z 分數為

$$z_A = \frac{690 - 780}{60} = -1.5, \quad z_B = \frac{660 - 720}{40} = -1.5.$$

兩人都比所在地平均快 1.5 個標準差，相對表現相同。此處較小的時間代表較佳表現，所以負 z 分數在語意上是高於平均的運動表現； z 的正負只描述數值方向，優劣取決於變量意義。

8. 核心整理

- 中心： $\bar{x} = \frac{1}{n} \sum x_i$ ；不同權重使用 $\bar{x}_w = \frac{\sum w_i x_i}{\sum w_i}$ ；連續倍率使用幾何平均。
- 排序：依課本規則先算 $I = nm/100$ ；非整數取第 $[I]$ 筆，整數取第 I 、 $I+1$ 筆平均。
- 分散： $s_x^2 = \frac{1}{n} \sum (x_i - \bar{x})^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2$ ， $s_x = \sqrt{s_x^2}$ 。
- 轉換：若 $Y = aX + b$ ，則 $\bar{Y} = a\bar{X} + b$ 、 $s_Y = |a|s_X$ 。
- 標準化： $z = (x - \bar{x})/s_x$ ，整組 z 分數平均為 0、標準差為 1。
- 相關： $r = \frac{1}{n} \sum z_{x_i} z_{y_i}$ ，且 $-1 \leq r \leq 1$ ；散布圖提供形狀、分群與特殊點資訊。
- 迴歸： $\hat{y} = a + bx$ ，其中 $b = r \frac{s_y}{s_x}$ 、 $a = \bar{y} - b\bar{x}$ ；直線通過 $(\bar{x}, \bar{y})$ 。
- 殘差： $e = y - \hat{y}$ ；殘差圖用來檢查線性模型是否留下系統性結構。