

數 2-4 數據分析

普通高中數學（必修・第二冊）・學生講義

一組數字本身難以一眼看出特徵：一次小考全班 40 人的成績是 40 個數字，直接看這 40 個數字，看不出「考得好不好」「分數散不散」。敘述統計（descriptive statistics）的工作，就是用少數幾個數字把一整組資料的特徵摘要出來。

本章先處理一維數據（每筆資料只有一個數字）：用集中量數描述「資料大致落在哪」，用離散量數描述「資料散得開不開」，再把每筆資料標準化成 z 分數，使不同尺度的資料能互相比較。接著處理二維數據（成對出現的資料）：用散布圖觀察兩個量的關係，用相關係數量化關係的方向與強弱，最後用最小平方法配出最適直線。本章是高中唯一的描述統計章節，以定性理解與基本計算為主。

本章主線：

集中量數與離散量數 → 線性變換的影響 → 標準化（ z 分數）→ 散布圖與相關 → 相關係數 → 最適直線（最小平方）

4-1 一維數據的集中與離散

A. 為什麼需要摘要一組數據

把一整組資料摘要成幾個數字，方向有兩個，缺一不可：

- 集中量數（measures of central tendency）：資料大致落在哪？——平均數、中位數、眾數。
- 離散量數（measures of dispersion）：資料散得開不開？——全距、四分位距、變異數、標準差。

只報集中量數而不報離散量數，會掩蓋關鍵資訊：兩組資料的平均數可能相同，分散程度卻天差地遠（本節稍後會看到）。

B. 集中量數：平均數、中位數、眾數

設一組數據為 $x_1, x_2, \dots, x_n$ ，共 n 筆。

- 算術平均數（arithmetic mean） $\bar{x}$ ：所有數值的總和除以筆數，

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

- 中位數（median）：把資料由小到大排序後位居正中間的數。 n 為奇數時取第 $\frac{n+1}{2}$ 個； n 為偶數時取中間兩個的平均。

- **眾數 (mode)**：出現次數最多的數值（可能不只一個，也可能沒有）。

注意：若資料中有一個離群的極大或極小值（**離群值**，outlier），平均數會明顯被它拉動，中位數則幾乎不受影響。例如 5 人的月薪為 3, 3, 4, 4, 100（萬元），平均數為 22.8 萬，但中位數仍是 4 萬。此時中位數更能代表「典型的人」。新聞報導「家戶所得中位數」而非平均數，正是這個理由。

C. 離散量數：全距、四分位距、變異數、標準差

集中量數無法回答「散不散」。最簡單的離散量數是**全距 (range)**：

$$\text{全距} = \text{最大值} - \text{最小值}.$$

全距計算最快，但只用到兩個極端值，浪費了中間所有資訊，且**對離群值極敏感**——一個離群值就能把全距撐大。

改良的辦法是「砍掉頭尾、只看中間一半資料的寬度」，這就是四分位距。把資料**由小到大**排序後，用三個分割點把它切成四等份：

- **第一四分位數 (first quartile) Q_1** ：位置在 25% 處，其左邊約有四分之一的資料。
- **第二四分位數 Q_2** ：即中位數，位置在 50% 處。
- **第三四分位數 (third quartile) Q_3** ：位置在 75% 處。

四分位距 (interquartile range, IQR) 定義為中間一半資料的寬度：

$$\text{IQR} = Q_3 - Q_1$$

IQR 越大，中間 50% 的資料散得越開。它只看中段、不理會頭尾的極端值，因此**不受離群值影響**——這正是它比全距好的地方。

求 Q_1 、 Q_3 的位置：高中採用的常見作法

資料筆數不是 4 的倍數時，各教科書求 Q_1, Q_3 的位置略有出入。高中階段以下面這個常見作法為準：先用中位數把資料切成左右兩半， Q_1 、 Q_3 各取左半、右半的中位數。例如 11 筆排序後的資料，中位數 Q_2 取第 6 個；以它為界，左半 5 筆的中位數即 Q_1 ，右半 5 筆的中位數即 Q_3 。

以 11 筆排序資料 3, 5, 6, 8, 9, 10, 12, 13, 15, 18, 21 為例（即上述作法），可算得 $Q_1 = 6$ 、 $Q_2 = 10$ 、 $Q_3 = 15$ ，故 $\text{IQR} = Q_3 - Q_1 = 9$ ，而全距 $= 21 - 3 = 18$ 。把這組資料畫成**盒鬚圖 (box plot)**，五個數與兩種離散量數的對照一目了然：

盒鬚圖：用五個數摘要一組資料的分布與離散



圖 4-1：盒鬚圖。藍色盒子的左右邊界是 $Q_1 = 6$ 、 $Q_3 = 15$ ，盒寬即 $IQR = 9$ （中間 50% 資料的範圍）；盒內紅線是中位數 $Q_2 = 10$ ；左右兩條「鬚」延伸到最小值 3 與最大值 21，兩端距離即全距 18。IQR 只量中段、全距才把最極端兩筆算進去，這正是 IQR 對離群值穩健的原因。

全距與四分位距都只用到少數幾個位置上的數。要善用**每一筆**資料，自然的想法是看每筆資料離平均數多遠，即偏差（deviation） $x_i - \bar{x}$ 。但偏差直接相加一定得到 0：

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n\bar{x} = n\bar{x} - n\bar{x} = 0.$$

這是因為平均數正是讓正負偏差互相抵消的那個「平衡點」。所以不能直接加偏差，必須先消去正負號。做法是**先把每個偏差平方**（消去正負號、且讓大偏差更顯著），取平均得到**變異數**；再開根號把單位變回原來的單位，得到**標準差**。

- 變異數（variance） σ^2 ：偏差平方的平均，

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

- 標準差（standard deviation） σ ：變異數開正的平方根，

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

標準差與原資料**同單位**（資料是公分，標準差也是公分），可直接解讀為「資料大致偏離平均多少」。實際手算時常用下面這條**展開公式**（先算「平方的平均」再減「平均的平方」）較快：

$$\sigma^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2.$$

標準差為什麼要「平方再開根號」？它到底在量什麼

標準差量的是「資料典型上偏離平均數多遠」——一個與原資料同單位的「平均離散程度」。標準差小，資料擠在平均附近；標準差大，資料散得開。

要消去偏差的正負號，取絕對值的平均（稱為平均差 $\frac{1}{n} \sum |x_i - \bar{x}|$ ）其實也是合理的離散量數。但統計學主流選了「平方再開根號」，理由有三：

1. 平方在數學上比絕對值好處理。絕對值函數 $|x|$ 在 0 處有尖點、不可微；平方函數 x^2 處處光滑、可微。後面配最適直線時要「求使某量最小」，平方能直接求極值，絕對值不行。
2. 開根號是為了把單位變回來。偏差平方後單位也平方了（公分變成平方公分），這叫變異數；開根號就是把單位開回原來的單位，所以標準差能直接解讀為「大約偏離平均幾公分」。
3. 平方讓大偏差被放大。偏差 10 貢獻 100，偏差 2 只貢獻 4，因此標準差對離群值較敏感——這在許多場合正是我們想要的。

注意：標準差不可能是負的（平方與開根號都非負）； $\sigma = 0$ 只發生在所有資料完全相同時。變異數是標準差的平方，兩者一體兩面：變異數方便做代數運算，標準差方便解讀（同單位）。




圖 4-2：兩組資料平均數都是 50，但甲組擠在平均附近（標準差約 1.4），乙組散得很開（標準差約 14.1）。標準差越大，資料越分散。

分母用 n 還是 $n - 1$ ？母體標準差與樣本標準差

本章公式分母用 n ，得到的是**母體標準差**——把手上這組資料當成「全部」來描述。在統計推論裡，若這組資料只是從更大母體抽出的**樣本**，要改用分母 $n - 1$ （**樣本標準差**，記作 s ）才能不偏地估計母體變異數。高中階段以分母 n 為主；但留意計算機常同時提供 σ_n 與 σ_{n-1} 兩鍵，按錯會得到不同答案。

D. 資料平移與伸縮對統計量的影響

實務上常需要對整組資料做同一個變換：攝氏改華氏、公分改公尺、全班加分。設把每筆資料 x_i 都換成

$$y_i = ax_i + b \quad (a, b \text{ 為常數}),$$

這稱為**線性變換** (linear transformation)。其中 b 是**平移** (translation) ——整組資料一起加減； a 是**伸縮** (scaling) ——整組資料一起放大或縮小。各統計量怎麼變，有一組固定的結論：

統計量	新值	說明
平均數	$\bar{y} = a\bar{x} + b$	平移與伸縮都影響
標準差	$\sigma_y = a \sigma_x$	只受伸縮影響，平移 b 完全無關
變異數	$\sigma_y^2 = a^2 \sigma_x^2$	同上，係數平方
全距 / 四分位距	各乘 $ a $	與標準差同理

一句話記住：「加減」（平移）只動集中量數、不動離散量數；「乘除」（伸縮）讓離散量數同步放大 $|a|$ 倍。

直觀理由：平移 $+b$ 把整組資料原封不動地搬走一段距離，資料彼此間的相對距離一點都沒變，所以衡量「散不散」的標準差、變異數、全距、四分位距全都不變；但每一筆都離原點遠了 b ，平均數自然跟著加 b 。伸縮 $\times a$ 則把所有間距同步拉成 $|a|$ 倍，離散量數隨之放大 $|a|$ 倍（取絕對值是因為 $a < 0$ 時資料左右翻轉，但「散開的程度」不會變成負的）。

注意：整組資料同加（或同減）一個常數，標準差、變異數、全距、四分位距都不變，這是最常被答錯的一點。常見的錯誤是以為「平均變了，離散量數也跟著變」。其實平移只是整體搬家，內部疏密不動；只有乘除（伸縮）才會改變離散程度。

4-2 數據的標準化

A. 為什麼要標準化

考慮一個問題：小明數學考 80 分、英文考 70 分，他哪一科考得「相對比較好」？不能直接比分数，因為兩科的難易與全班分布不同。80 分若全班平均 85，其實偏低；70 分若全班平均 50，反而很突出。

要回答「相對位置」，得同時考慮離平均多遠以及全班有多分散。把「偏差」用「標準差」當尺度量出來，就得到**標準分數**。設一組數據平均數 $\bar{x}$ 、標準差 σ ，把每筆資料 x 換成

$$z = \frac{x - \bar{x}}{\sigma}$$

稱為**標準化** (standardization)， z 稱為**標準分數** (standard score) 或 z 分數 (z-score)。它表示「 x 在平均數的上方（或下方）幾個標準差」。標準化後的新資料 $z_1, \dots, z_n$ 有兩個固定性質：

$$\bar{z} = 0, \quad \sigma_z = 1.$$

也就是說，任何一組資料標準化後，平均數一律變成 0、標準差一律變成 1。這把所有資料拉到「同一把尺」上，才能公平比較。

把分數變成 z 分數到底有什麼用？

標準化是把「原始分數」換成「離平均幾個標準差」。它把不同尺度、不同單位的資料，都拉到同一把尺（平均 0、標準差 1）上，於是原本不能比的東西變得可以公平比較。

可類比為「不同貨幣不能直接比金額」：手上有 100 日圓和 100 新台幣，數字一樣大，但價值天差地遠；要比較，得先換成同一種貨幣。標準化就是統計上的「換匯」，換算的辦法很自然：

$$z = \frac{x - \bar{x}}{\sigma} = \frac{\text{離平均多遠（偏差）}}{\text{這組資料的離散尺度（標準差）}}.$$

- 分子 $x - \bar{x}$ ：先看「離平均多遠」，但這個距離的「大小感」取決於整組散不散。
- 除以 σ ：用標準差當尺，把距離換算成「幾個標準差」。在很集中的資料裡偏離一點點就很突出（ z 大）；在很分散的資料裡偏離同樣的量卻不算什麼（ z 小）。

結果 z 沒有單位（分子分母的單位互相約掉），所以數學分數的 z 和英文分數的 z 可以直接比。

為什麼化後一定是「平均 0、標準差 1」？標準化其實是 4-1 D 小節線性變換 $y = ax + b$ 的特例（取 $a = \frac{1}{\sigma}$ 、 $b = -\frac{\bar{x}}{\sigma}$ ）。代入那組結論立刻得 $\bar{z} = \frac{1}{\sigma}\bar{x} - \frac{\bar{x}}{\sigma} = 0$ 、 $\sigma_z = \frac{1}{\sigma} \cdot \sigma = 1$ 。直觀地說，減去 $\bar{x}$ 把中心搬到 0，除以 σ 把尺度縮成 1。

標準化： $z = (x - \text{平均}) / \text{標準差}$ ，把不同尺度化為同一把尺




圖 4-3：原始分布平均 70、標準差 8，原始分數 86 在平均上方 2 個標準差處；標準化後整個分布平移縮放，原來的 86 對應到 $z = +2$ 。

由 $z = \frac{x - \bar{x}}{\sigma}$ 反解，可由 z 分數回推原始分數：

$$x = \bar{x} + z\sigma.$$

注意：

- z 分數沒有單位，所以才能跨不同單位的資料比較。
- $z > 0$ 只代表「在平均之上」，不代表及格或表現好，要看相對於整體分布的位置； $z = 0$ 表示恰好等於平均，不是 0 分。
- 標準化是平移加伸縮的線性變換，它改變數值與單位，但不改變資料的相對名次與分布形狀（原本第 3 名的人，標準化後仍是第 3 名；原本左偏的分布，化後一樣左偏）。

- 標準化不會把資料變成常態分布。「化成平均 0、標準差 1」與「化成鐘形」是兩回事；只有原本就接近常態的資料，化後才接近標準常態。

4-3 二維數據與散布圖

A. 從一維到二維

前兩節每筆資料只有一個數字（一維）。但現實常成對出現：每位學生有「身高」與「體重」、每天有「氣溫」與「冰品銷量」。這種成對的資料 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 稱為二維數據 (bivariate data)。我們想知道的是： x 與 y 之間有沒有關係？

把每一組 (x_i, y_i) 當成坐標平面上的一個點畫出來，所得的圖稱為**散布圖** (scatter plot)。從點的整體走向就能初步判斷 x 與 y 的關係：

- 正相關 (positive correlation)**： x 增大時 y 傾向增大，散布圖整體由左下往右上。
- 負相關 (negative correlation)**： x 增大時 y 傾向減小，整體由左上往右下。
- 零相關／無相關**：看不出隨 x 變化的方向性，點四散。

又依點貼近一條直線的程度，分為**強相關**（點緊貼一條直線）與**弱相關**（點鬆散但仍有趨勢）。




圖 4-4：散布圖的三種走向。左——正相關（左下到右上）；中——負相關（左上到右下）；右——近乎無相關（看不出隨 x 的趨勢）。

注意：散布圖呈現的「相關」專指**線性（直線）關係**的傾向。若 x, y 是明確的拋物線關係（如沿 $y = x^2$ 對稱取點），散布圖雖有清楚規律，但「直線相關」卻可能接近 0。**無線性相關不等於無任何關係**。此外，判斷時要看整體走向，不要只看單一極端點就斷定相關方向。

4-4 相關係數與最適直線

A. 相關係數：把「相關」化成一個數

散布圖讓人「看出」相關，但「看」帶有主觀。**相關係數** (correlation coefficient) r 用一個介於 -1 與 1 的數字，客觀量化線性相關的方向與強弱。它的構造延續前面兩節的精神：把 x 與 y

各自標準化，再看兩者的乘積平均。設 x 的平均與標準差為 $\bar{x}, \sigma_x$ ， y 的為 $\bar{y}, \sigma_y$ ，則

$$r = \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \bar{x})(y_i - \bar{y})}{\sigma_x \sigma_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$

其性質為 $-1 \leq r \leq 1$ ，且：

- $r > 0$ 正相關， $r < 0$ 負相關， $r \approx 0$ 無線性相關；
- $|r|$ 越接近 1，點越貼近一條直線（相關越強）； $r = \pm 1$ 表示所有點恰好共線。

分子 $\sum (x_i - \bar{x})(y_i - \bar{y})$ 的意義是：當 x 在平均之上時 y 也常在平均之上（兩偏差同號、乘積為正），總和為正，就是正相關；反之為負相關。分母用兩個標準差把它「標準化」，使結果落在 $[-1, 1]$ 、且與單位無關。

r 為什麼一定介於 -1 與 1 ？

把每筆資料標準化：令 $u_i = \frac{x_i - \bar{x}}{\sigma_x}$ 、 $v_i = \frac{y_i - \bar{y}}{\sigma_y}$ 。則相關係數正是這兩組標準分數乘積的平均：

$$r = \frac{1}{n} \sum_{i=1}^n u_i v_i.$$

而 u, v 各自的「標準差為 1」意味著 $\frac{1}{n} \sum u_i^2 = 1$ 、 $\frac{1}{n} \sum v_i^2 = 1$ 。接著用「任何實數的平方都非負」夾出範圍。考慮

$$\frac{1}{n} \sum_{i=1}^n (u_i - v_i)^2 \geq 0,$$

展開後利用上面兩個等於 1 的和：

$$\frac{1}{n} \sum (u_i^2 - 2u_i v_i + v_i^2) = 1 - 2r + 1 = 2 - 2r \geq 0,$$

所以 $r \leq 1$ 。同理對 $\frac{1}{n} \sum (u_i + v_i)^2 \geq 0$ 展開得 $2 + 2r \geq 0$ ，即 $r \geq -1$ 。合起來即 $-1 \leq r \leq 1$ 。等號何時成立？ $r = 1$ 當且僅當每個 $u_i = v_i$ ，即所有點恰好落在一條斜率為正的直線上； $r = -1$ 當且僅當每個 $u_i = -v_i$ ，所有點落在一條斜率為負的直線上。換言之， $|r| = 1$ 就是「完美的線性關係」。

延伸閱讀 | r 與向量內積：柯西不等式的特例

把 $(u_1, \dots, u_n)$ 與 $(v_1, \dots, v_n)$ 看成兩個 n 維向量，相關係數 $r = \frac{1}{n} \sum u_i v_i$ 正好是兩向量的「正規化內積」，也就是它們夾角的餘弦。餘弦的絕對值不超過 1，這正是 $|r| \leq 1$ 的另一個來源，屬於高二向量內積裡柯西不等式 (Cauchy inequality) 的一個特例。從這個角度看，「相關係數」其實在度量兩組標準化資料的「方向有多接近」：方向完全一致時 $r = 1$ ，完全相反時 $r = -1$ ，互相垂直時 $r = 0$ 。

B. 最適直線（迴歸直線）

當 x, y 有線性相關時，希望找一條直線 $y = a + bx$ **最能代表**這群點，用來描述趨勢、或由 x 預測 y 。問題是：怎樣算「最能代表」？對直線 $y = a + bx$ ，第 i 筆資料的**殘差**（residual）是「實際 y_i 」與「直線預測值 $a + bx_i$ 」的鉛直差：

$$e_i = y_i - (a + bx_i).$$

最小平方方法（method of least squares）：選 a, b 使**殘差平方和** $\sum_{i=1}^n e_i^2$ 最小。所得直線稱為**最適直線**或**迴歸直線**（regression line）。




圖 4-5：橘色虛線是各點的殘差（資料點到直線的鉛直距離）。最適直線就是讓這些殘差「平方後加起來」最小的那條，且必通過平均點。

可證明最小平方解為：

$$b = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = r \frac{\sigma_y}{\sigma_x}, \quad a = \bar{y} - b\bar{x}$$

由 $a = \bar{y} - b\bar{x}$ 知迴歸直線**必通過平均點** $(\bar{x}, \bar{y})$ （把 $x = \bar{x}$ 代入得 $y = a + b\bar{x} = \bar{y}$ ）。斜率 b 與相關係數 r **同號**（因 $\sigma_x, \sigma_y > 0$ ）。式子 $b = r \frac{\sigma_y}{\sigma_x}$ 把全章串起來：相關係數、標準差、迴歸斜率原來是同一家人—— r 管方向與強弱， $\frac{\sigma_y}{\sigma_x}$ 把 x 的尺度換成 y 的尺度。

最適直線的公式是怎麼來的？最小平方方法

把「直線與資料的不合身程度」定義成**殘差平方和**，它是 a, b 的二次函數；讓這個二次函數最小，就解出上面那兩條公式。整個推導就是「二次函數求極小」。目標函數為

$$S(a, b) = \sum_{i=1}^n [y_i - (a + bx_i)]^2.$$

S 對 a 、對 b 都是開口向上的二次式，必有唯一最小值。

第一步——先固定 b ，看成 a 的二次函數。 $S = \sum[(y_i - bx_i) - a]^2$ 是「一堆數 $y_i - bx_i$ 到 a 的距離平方和」，由二次函數配方知，當 a 取這堆數的平均時最小：

$$a = \frac{1}{n} \sum (y_i - bx_i) = \bar{y} - b\bar{x}.$$

這立刻說明迴歸直線通過平均點 $(\bar{x}, \bar{y})$ 。

第二步——把 $a = \bar{y} - b\bar{x}$ 代回。令 $X_i = x_i - \bar{x}$ 、 $Y_i = y_i - \bar{y}$ ，殘差變成 $Y_i - bX_i$ ，於是

$$S(b) = \sum (Y_i - bX_i)^2 = \left(\sum X_i^2 \right) b^2 - 2 \left(\sum X_i Y_i \right) b + \sum Y_i^2,$$

這是 b 的二次函數，開口向上 ($\sum X_i^2 > 0$)，頂點在

$$b = \frac{\sum X_i Y_i}{\sum X_i^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2},$$

即課本的斜率公式。上下同除以 n ，分子是共變數、分母是 σ_x^2 ，可改寫成 $b = r \frac{\sigma_y}{\sigma_x}$ 。

注意：最小平方量的是鉛直距離 (y 方向的殘差)，不是點到直線的垂直距離，因為迴歸的目的是「用 x 預測 y 」，在意的是 y 預測得準不準。也因為這個不對稱，「 x 對 y 的迴歸線」和「 y 對 x 的迴歸線」一般是兩條不同的線，只有 $r = \pm 1$ (完美共線) 時才重合。本章以「由 x 預測 y 」為準。

C. 兩個務必小心的觀念

相關 $\neq$ 因果。 r 大只說明「兩量一起變化」，不保證一個是另一個的原因。把相關當因果，是新聞、廣告、偽科學最常見的誤導手法。兩個變數高度相關，可能來自下列任一種情形，只有第一種才是真因果：

1. **真有因果：** x 確實造成 y (如施肥量增加使產量增加)。
2. **共同原因 (潛在變數, lurking variable)：** x, y 都被第三個變數帶動，彼此卻無因果。經典例：**冰品銷量與溺水人數**高度正相關，但吃冰不會害人溺水，背後共同原因是**氣溫** (天熱時兩者都上升)；某地區**消防車數量與火災損失**正相關，不是消防車造成損失，而是「火勢大」同時帶動兩者。
3. **因果方向相反：**其實是 y 造成 x ，而非 x 造成 y 。
4. **巧合 (虛假相關)：**尤其在資料量小或硬湊變數時，會出現毫無意義卻數值很高的相關。

不要外推太遠。迴歸直線是由現有資料範圍配出來的；拿它去預測遠在資料範圍外的 x (外插，extrapolation) 很危險，因為趨勢未必延續。

延伸閱讀 | 怎樣才能確定因果？

觀察到的相關不足以確立因果。要談因果，須靠**對照實驗**：把對象隨機分成實驗組與對照組，控制其他變數只讓所研究的因素不同，再比較結果。隨機分組的用意，是把各種未知的潛在變數平均分散到兩組，使兩組「除了被研究的因素以外大致相同」，這樣若仍看到差異，才較有把握歸因於該因素。這套方法是實驗科學與醫學試驗的基礎，細節超出高中範圍，但「相關要升級成因果，需要的是實驗而非更大的 r 」這個原則值得記住。

4-5 本章重點整理

一頁複習（公式與關鍵結論）

- **集中量數**：平均數 $\bar{x} = \frac{1}{n} \sum x_i$ 、中位數（排序取中）、眾數（最常出現）。極端值大幅影響平均數，幾乎不影響中位數。
- **離散量數**：全距 = 最大 - 最小；四分位距 $IQR = Q_3 - Q_1$ （中間 50% 的寬度，對離群值穩健）；變異數 $\sigma^2 = \frac{1}{n} \sum (x_i - \bar{x})^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2$ ；標準差 $\sigma = \sqrt{\sigma^2}$ （與資料同單位）。標準差非負， $\sigma = 0$ 只在資料全相同時。
- **線性變換** $y = ax + b$ ： $\bar{y} = a\bar{x} + b$ ； $\sigma_y = |a|\sigma_x$ 、 $\sigma_y^2 = a^2\sigma_x^2$ 、全距與 IQR 各乘 $|a|$ 。平移（加減 b ）不改變任何離散量數，只有伸縮（乘 a ）才改變。
- **標準化**： $z = \frac{x - \bar{x}}{\sigma}$ （線性變換的特例），化後平均 0、標準差 1，無單位，可跨尺度比較相對位置；反推 $x = \bar{x} + z\sigma$ 。不改名次、不改分布形狀。
- **二維數據**：散布圖看走向 → 正相關 / 負相關 / 無相關。無線性相關不等於無任何關係。
- **相關係數**： $r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$ ， $-1 \leq r \leq 1$ ， $|r|$ 越大線性越強， $r = \pm 1$ 為完美共線。相關不等於因果。
- **最適直線（最小平方）**： $b = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = r \frac{\sigma_y}{\sigma_x}$ ， $a = \bar{y} - b\bar{x}$ ，必過平均點 $(\bar{x}, \bar{y})$ ；斜率與 r 同號。量的是鉛直殘差，故 x 對 y 與 y 對 x 的迴歸線一般不同。