

數 A4-3 機率統計

普通高中數學（數學 A・第四冊）・學生講義

在第一冊的排列組合與機率中，學到的是「算一個事件的機率」：樣本空間、古典機率與期望值。本章往前一步，探討事件彼此之間的關係。

主線分三段。先把「機率到底是什麼意思」釐清，區分主觀機率（subjective probability）與客觀機率（objective probability）。接著進入條件機率（conditional probability）：「已知一件事發生後，另一件事的機率如何改變」，並由它導出乘法公式（multiplication rule）、事件的獨立（independence），以及必須與「互斥」分清楚的觀念。最後把這些組合起來，得到全機率公式（law of total probability）與貝氏定理（Bayes' theorem），學會把判斷從「先驗（prior）」修正到「後驗（posterior）」，並用它解釋為什麼「篩檢驗出陽性，不等於真的得病」。

條件機率與貝氏定理是現代資料科學、機器學習與醫學決策的共同語言，也是大學機率論與統計推論的起點。

本章主線：

兩種機率（主觀／客觀）→ 條件機率 → 乘法公式 → 獨立性（與互斥區分）→ 全機率公式 → 貝氏定理（篩檢偽陽性）

4-3-1 主觀機率與客觀機率

A. 「機率是 0.7」到底在說什麼

「機率」這個詞，其實有兩種意思不同的用法。

- 「明天降雨機率 70%」——這是對一件只會發生一次的事（明天）所下的判斷。
- 「這顆公正硬幣出現正面的機率是 $\frac{1}{2}$ 」——這是因為硬幣兩面對稱、等可能，或因為「丟很多次，大約一半是正面」。

這兩種用法背後，是兩種不同的機率觀。

兩種機率觀：客觀機率與主觀機率

客觀機率（objective probability）：機率是事物本身的客觀性質，與「誰在猜」無關。它有兩個來源：

- **古典（對稱）觀**：當所有基本結果等可能時，

$$P(A) = \frac{\text{有利結果數}}{\text{全部結果數}}.$$

這就是第一冊學的古典機率。

- **頻率（次數）觀**：在相同條件下重複大量試驗，事件 A 出現的相對次數會逐漸穩定，

這個穩定值即為 $P(A)$ ：

$$P(A) \approx \frac{A \text{ 出現的次數}}{\text{試驗總次數}} \quad (\text{試驗次數很大時}).$$

主觀機率 (subjective probability)：機率是「某個人對某件事的相信程度」，用 0 到 1 的數字表示（0 表示完全不信會發生，1 表示確信會發生，0.5 表示一半一半）。「明天降雨 70%」「某球隊奪冠機率三成」都屬此類——這些事無法重複試驗，但人仍須對它下判斷。

B. 由數據獲得客觀機率（相對次數）

當一件事沒有明顯的對稱性可用（例如一顆做工不均的圖釘，丟下去尖朝上的機率），便無法用古典機率直接計算。這時只能靠**做實驗、數次數**：把圖釘丟很多次，記錄尖朝上的累計相對次數。隨著試驗次數增加，相對次數會**逐漸穩定**在某個值附近，這個穩定值即為機率的估計。試驗次數越多，估計越可靠。

注意：試驗次數太少時，相對次數會劇烈跳動，不能當作機率。例如「丟 10 次有 7 次正面，所以正面機率 0.7」並不成立——十次的結果只是一次抽樣，運氣成分很大。頻率觀的機率是**試驗次數趨於很大時**相對次數的穩定值（大數法則）。

C. 用機率的性質檢驗主觀機率

主觀機率雖然是「個人的相信程度」，但**不能任意給定**：只要它要被當成機率使用，就**必須遵守機率的基本性質**，否則會自相矛盾。

機率公理：任何機率都要滿足

設樣本空間為 S ，事件 $A, B \subseteq S$ ：

$$0 \leq P(A) \leq 1, \quad P(S) = 1, \quad P(\emptyset) = 0.$$

兩事件互斥（ $A \cap B = \emptyset$ ，不會同時發生）時： $P(A \cup B) = P(A) + P(B)$ 。由此可得**餘事件與加法定理**：

$$P(A^c) = 1 - P(A)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

舉例而言，若某球評對甲、乙、丙三隊奪冠給的主觀機率分別是 0.5、0.4、0.3，由於奪冠是互斥事件且三隊之外無人能奪冠，三者機率**總和應為 1**；但 $0.5 + 0.4 + 0.3 = 1.2 > 1$ ，違反「總機率為 1」，因此這組判斷**不合理**，至少要調整其中一個數字。

客觀機率與主觀機率並非對立，而是**回答不同問題的工具**：可重複、有對稱性的事（骰子、抽球）用客觀機率；一次性、無法重複的事（明天、選舉、某病人）只能用主觀機率，但它仍須服從機率公理。本章 4-3-3 的貝氏統計，正是把主觀機率（先驗）拿來，用數據（客觀）一步步修正。

延伸閱讀 | 主觀機率「憑感覺講的數字」，憑什麼也叫機率？

客觀機率有「等可能」或「重複試驗」撐腰，主觀機率兩者都沒有。關鍵在於：一個數字能

否被當成「機率」，重點不是它怎麼來的，而是它有沒有遵守機率的規則。主觀機率雖然來源是個人判斷，但只要服從機率公理（每個機率在 0 到 1 之間、互斥又窮盡的可能機率總和為 1、包含關係一致），就能和客觀機率一樣參與運算（加法、乘法、貝氏更新）。

主觀機率為何非得服從公理不可，有一個很實際的理由：**如果主觀機率不一致，別人可以設計一組賭局，讓你無論結果如何都穩輸**。這在機率論裡稱為「荷蘭賭（Dutch book）」。換句話說，服從機率公理不只是數學要求，也是不被套利的理性底線。這也說明合理的主觀機率，與客觀機率服從**完全相同**的規則。

常見誤解是「主觀就是不準、客觀就是準」。兩者回答的是**不同問題**，沒有誰比較準的問題。氣象的「降雨 70%」其實是用大量歷史相似天氣資料校準過的，相當可靠；要評估它準不準，須看「所有報 70% 的日子裡，是否約七成真的下雨」。

4-3-2 條件機率與獨立性

A. 已知一個情報，機率就改變

擲一顆公正骰子，「出現 6 點」的機率是 $\frac{1}{6}$ 。但若已知「這次擲出的是偶數」，「是 6 點」的機率還是 $\frac{1}{6}$ 嗎？

不是了。既然已知是偶數，可能的結果只剩 $\{2, 4, 6\}$ 三個，而 6 是其中之一，機率變成 $\frac{1}{3}$ 。

關鍵轉變在於：一旦「已知 B 發生」，考慮的範圍就從整個樣本空間 S 縮小成 B 。原本要在 S 裡算比例，現在改在 B 裡算比例。這個「在 B 之內、 A 佔多少」的機率，就是**條件機率**。

定義：條件機率


在「事件 B 已發生」的條件下，事件 A 發生的機率，記作 $P(A | B)$ （讀作「在 B 之下 A 的機率」）。當 $P(B) > 0$ 時，

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$


直覺：分母從整個 S 換成 B （新的「全部」），分子是「同時在 A 又在 B 」的部分（ $A \cap B$ ，新世界裡屬於 A 的部分）。

條件機率：把分母從 U 換成 B

原本：在整個 U 裡看



已知 B 發生：世界縮小成 B



$$P(A | B) = \frac{P(A \cap B)}{P(B)} \quad (A \cap B \text{ 在 } B \text{ 裡佔多少})$$

圖 4-3-1：條件機率把分母從 S 換成 B 。左——原本在整個樣本空間裡看 A ；右——已知 B 發生後世界縮小成 B ，只剩 $A \cap B$ 這塊算數， $P(A | B)$ 即 $A \cap B$ 在 B 裡所佔的比例。

為什麼分母換成 $P(B)$ 、分子換成 $P(A \cap B)$

把樣本空間想成一整片草地， A 、 B 是其上兩塊（可能重疊）的區域。

還沒有任何情報時，「 A 的機率」就是「 A 這塊地佔整片草地多少」。現在已知「 B 發生」，表示真正的結果一定落在 B 裡， B 以外的部分全部可以劃掉，世界縮小成只剩 B 。在這個小世界裡再問「 A 的機率」，就是問「在 B 之內、屬於 A 的部分佔多少」，而「在 B 裡又屬於 A 」的部分正是重疊 $A \cap B$ 。因此

$$P(A | B) = \frac{A \cap B \text{ 的面積}}{B \text{ 的面積}} = \frac{P(A \cap B)}{P(B)}.$$

- **分母換成 $P(B)$** ：新世界的「全部」就是 B ，要拿它當分母，使新世界的總機率重新變回 1 ($P(B | B) = \frac{P(B)}{P(B)} = 1$)。
- **分子換成 $P(A \cap B)$** ：新世界裡能算數的，只有「同時也在 B 裡」的那部分 A ，落在 B 外的 A 已被劃掉。

除法的本質就是「重新標準化」：把舊世界的機率，按新世界的大小 $P(B)$ 重新縮放回「總和為 1」。

注意：條件機率不一定比原機率小。情報可能讓機率變大、變小或不變——例如已知「是偶數」後，「是 6 點」從 $\frac{1}{6}$ 升到 $\frac{1}{3}$ （變大）。另外要區分 $P(A | B)$ 與 $P(A \cap B)$ ：後者是「在原本的大世界裡， A 、 B 同時發生」的機率；前者是「已假定 B 發生後」 A 的機率，分母不同，數值通常不同。更重要的是，條件不能隨意反過來：一般情況下

$$P(A | B) \neq P(B | A).$$

例如「是 6 點」在「偶數」裡佔 $\frac{1}{3}$ ，但「偶數」在「6 點」裡佔 1（已知是 6 點，當然是偶數），兩者差很多。這個方向性，正是 4-3-3 貝氏定理要處理的核心。

B. 乘法公式

把條件機率的定義移項，就得到一個算「兩件事接連都發生」的工具。

定義：機率的乘法公式

由 $P(A | B) = \frac{P(A \cap B)}{P(B)}$ 移項：

$$P(A \cap B) = P(B) P(A | B) = P(A) P(B | A).$$

文字版：「 A 、 B 都發生」的機率 = 「先發生其中一件」乘上「在那之後另一件也發生」。推廣到三件事（連續抽取最常用）：

$$P(A \cap B \cap C) = P(A) P(B | A) P(C | A \cap B).$$

乘法公式最典型的用途是**不放回連抽**。例如袋中 5 紅 3 白共 8 顆，不放回連抽兩顆，「兩顆都紅」的機率為

$$P(\text{第一紅}) \times P(\text{第二紅} \mid \text{第一紅}) = \frac{5}{8} \times \frac{4}{7} = \frac{5}{14}.$$

重點在於：不放回時，第二次的機率**依賴**第一次的結果（已抽走一紅，剩 4 紅、共 7 顆），所以第二次一定要用**條件機率** $\frac{4}{7}$ ，不能寫成 $\frac{5}{8}$ 。

C. 事件的獨立性

上面「不放回」時，第一次的結果**改變**了第二次的機率（ $\frac{5}{8} \rightarrow \frac{4}{7}$ ）。但如果是**放回**再抽，第二次抽之前袋子完全恢復原狀，「第一次抽到什麼」對第二次**毫無影響**。這種「一件事發生與否，不改變另一件事的機率」，就是**獨立**。

定義：兩事件獨立

若「 B 是否發生」不影響 A 的機率，即 $P(A \mid B) = P(A)$ ，則稱 A 、 B **獨立 (independent)**。把它代回乘法公式 $P(A \cap B) = P(B)P(A \mid B)$ ，得到**對稱、好記、也是正式定義**的判準：

$$A, B \text{ 獨立} \iff P(A \cap B) = P(A)P(B).$$

直觀：獨立時「兩件都發生」的機率，就是各自機率**直接相乘**（不必管誰先誰後、誰影響誰）。

由此可看出「放回 vs 不放回」的差別：同樣 5 紅 3 白連抽兩顆求「兩顆都紅」，**放回**時兩次獨立， $P = \frac{5}{8} \times \frac{5}{8} = \frac{25}{64}$ ；**不放回**時兩次不獨立， $P = \frac{5}{8} \times \frac{4}{7} = \frac{5}{14}$ 。兩者不同。判斷一題該怎麼乘，先問自己：第二次的機率有沒有被第一次改變？

D. 獨立不等於互斥（最容易混淆，務必分清）

「獨立」和「互斥」是最常被混為一談的兩個詞，但它們講的是**完全不同的事**，甚至幾乎**相反**：

- **互斥 (mutually exclusive)**：兩件事**不會同時發生**， $A \cap B = \emptyset$ ，即 $P(A \cap B) = 0$ 。問的是「能不能同時發生」。
- **獨立 (independent)**：一件事發生**不影響**另一件事的機率， $P(A \cap B) = P(A)P(B)$ 。問的是「會不會互相影響」。

互斥 $\neq$ 獨立：互斥是「不會同時發生」，獨立是「互不影響」




圖 4-3-2：互斥與獨立的對照。左——互斥的兩圓完全分開 ($A \cap B = \emptyset$, $P(A \cap B) = 0$)；右——獨立的兩圓相交，重疊比例恰好等於各自比例相乘 ($P(A \cap B) = P(A)P(B) \neq 0$)。

為什麼互斥的兩個正機率事件「反而不獨立」

關鍵在於：互斥其實是一種最強烈的「互相影響」。若 A 、 B 互斥，那麼「 B 一旦發生， A 就絕不可能發生」。用條件機率寫出來：

$$P(A | B) = \frac{P(A \cap B)}{P(B)} = \frac{0}{P(B)} = 0.$$

本來 A 有 $P(A) > 0$ 的機率，一聽到「 B 發生」就直接掉到 0——這影響大得不能再大，怎麼可能是「互不影響」（獨立）？

用數學確認：兩個正機率事件 A 、 B 若互斥，則

$$P(A \cap B) = 0, \quad P(A)P(B) > 0,$$

兩者不相等，所以不獨立。一句話記住：「互斥」是不會一起來；「獨立」是來不來互不干涉。兩個正機率事件若互斥，就一定不獨立。

唯一的退化例外：若其中一個事件機率為 0（如不可能事件），則 $P(A \cap B) = 0 = P(A)P(B)$ 同時成立，此時互斥與獨立可兼得；但這只是「機率為 0」的瑣碎情形，理解主旨即可。

要小心兩個常見誤解：其一是「獨立＝沒有交集」——也錯，獨立的兩圓一定有交集 ($P(A \cap B) = P(A)P(B) > 0$)，沒有交集（互斥）的反而不獨立。其二是把互斥當成獨立——剛好相反，兩個正機率事件互斥就保證不獨立。實務上判斷一題屬於哪一種，可循下列線索：

- 「抽完不放回、抽走就少一個」 $\Rightarrow$ 前後不獨立（會互相影響）。
- 「放回、兩顆不同的骰子或硬幣、兩個無關的人」 $\Rightarrow$ 多半獨立。
- 「同一次試驗的不同結果（如出現 1 或出現 2）」 $\Rightarrow$ 互斥。
- 不確定時回到定義硬算：互斥看 $A \cap B$ 是不是空；獨立看 $P(A \cap B)$ 是否等於 $P(A)P(B)$ 。

實際上，大多數真實事件既不互斥也不獨立（兩圓有交集，但重疊比例不等於各自比例相乘），這是最常見的情形。

4-3-3 貝氏定理

A. 全機率公式：先分類，再加總

很多問題裡，一個結果可以來自好幾種不同的「來源」，而每個來源出這個結果的機率不一樣。例如一間工廠的產品來自機台 A 或 B，兩台的不良率不同，問「隨手抽一件，是不良品的機率」。

做法是把整個樣本空間依來源切成幾塊（彼此互斥、合起來涵蓋全部，稱為一組分割，partition），分別算每塊貢獻的機率，再加起來。

定義：全機率公式

設 $B_1, B_2, \dots, B_n$ 把樣本空間互斥且窮盡地分割（任兩不相交、合起來是全部），每個 $P(B_i) > 0$ 。則對任一事件 A ：

$$P(A) = \sum_{i=1}^n P(B_i) P(A | B_i).$$

兩塊的版本（最常用）：

$$P(A) = P(B) P(A | B) + P(B^c) P(A | B^c).$$

直覺： A 發生的總機率＝把「經由每一條來源路徑到達 A 的機率」全部加起來（樹狀圖中每條路徑相乘、各路徑相加）。




圖 4-3-3：全機率公式的樹狀圖。先依來源分岔（機台 A 佔 0.6、機台 B 佔 0.4），每條路徑把分岔機率相乘，再把所有通往「不良」的路徑相加，得到總不良率 $0.6 \times 0.05 + 0.4 \times 0.10 = 0.07$ 。

以圖 4-3-3 的工廠為例：60% 來自機台 A、40% 來自機台 B，A 的不良率 5%、B 的不良率 10%。設 $D = \text{「不良」}$ ，則

$$P(D) = P(A)P(D | A) + P(B)P(D | B) = 0.6 \times 0.05 + 0.4 \times 0.10 = 0.07.$$

整體不良率 7%，介於 5% 與 10% 之間，且偏向佔比較大的 A，合理。

B. 貝氏定理：把條件反過來

上面算的是「已知來自某機台，是不良品的機率」($P(D | A)$)，由因到果。但實務上常拿到的是相反的問題：「已知抽到的是不良品，它來自機台 A 的機率是多少」($P(A | D)$)，由果到因。

前面已說明 $P(A | B) \neq P(B | A)$ ，所以不能把 $P(D | A)$ 直接當成 $P(A | D)$ 。把兩個方向接起來的橋樑，就是貝氏定理。

定義：貝氏定理

由乘法公式 $P(A \cap D) = P(A)P(D | A) = P(D)P(A | D)$ ，移項即得：

$$P(A | D) = \frac{P(A) P(D | A)}{P(D)}.$$

把分母 $P(D)$ 用全機率公式展開（兩塊版）：

$$P(A | D) = \frac{P(A) P(D | A)}{P(A) P(D | A) + P(A^c) P(D | A^c)}.$$

- $P(A)$ ：先驗機率（prior）——還沒看到證據 D 之前，對 A 的判斷。
- $P(A | D)$ ：後驗機率（posterior）——看到證據 D 之後，修正過的判斷。

貝氏定理就是「看到證據後，如何把先驗更新成後驗」的公式。

承上工廠例：已知抽到的是不良品，求它來自機台 A 的機率。先驗 $P(A) = 0.6$ ，似然 $P(D | A) = 0.05$ ，分母 $P(D) = 0.07$ ，故

$$P(A | D) = \frac{0.6 \times 0.05}{0.07} = \frac{0.03}{0.07} = \frac{3}{7} \approx 0.43.$$

機台 A 雖佔產量 6 成（先驗 0.6），但因不良率低，「不良品裡來自 A 的」只佔約 43%——看到「不良」這個證據後，對 A 的判斷從 0.6 降到 0.43。

C. 經典應用：疾病篩檢的偽陽性

貝氏定理最有名、也最違反直覺的應用，是醫學篩檢：一個準確率聽起來很高的檢驗，驗出陽性時，受檢者真正得病的機率卻可能很低。

考慮一種疾病，人群中的盛行率為 1%。某檢驗的敏感度（sensitivity）99%（得病者驗出陽性的機率）、特異度（specificity）95%（沒病者驗出陰性的機率）。設 S = 「得病」、 T = 「驗出陽性」，已知

$$P(S) = 0.01, \quad P(S^c) = 0.99, \quad P(T | S) = 0.99, \quad P(T | S^c) = 1 - 0.95 = 0.05.$$

先用全機率公式算「驗出陽性的總機率」：

$$P(T) = P(S)P(T | S) + P(S^c)P(T | S^c) = 0.01 \times 0.99 + 0.99 \times 0.05 = 0.0594.$$

再用貝氏定理算後驗：

$$P(S | T) = \frac{P(S)P(T | S)}{P(T)} = \frac{0.0099}{0.0594} \approx 0.167.$$

即使驗出陽性，真正得病的機率也只有約 16.7%；換句話說，陽性者裡超過八成是虛驚一場（偽陽性）。


用「自然頻率」想最清楚：為什麼答案這麼低

把抽象的機率換成具體人數就一目了然。假設 10000 人受檢：

- 真正得病的有 $10000 \times 1\% = 100$ 人，其中 $100 \times 0.99 \approx 99$ 人驗出陽性（真陽性）。
- 沒病的有 9900 人，其中 $9900 \times 5\% = 495$ 人也驗出陽性（偽陽性）。
- 驗出陽性的共 $99 + 495 = 594$ 人，真得病的只有 99 人： $\frac{99}{594} \approx 16.7\%$ 。

關鍵：健康的人基數太大（9900 人），即使偽陽性率只有 5%，乘上 9900 也產生 495 個偽陽性，遠多於 99 個真陽性。盛行率（先驗）越低，這個「基數效應」越嚴重，後驗就被壓得越低。

篩檢陽性 ≠ 真的得病：偽陽性把後驗機率壓低
10000 人（每格 1 人），盛行率 1%



- 真陽性（得病，驗出）：99
 - 偽陰性（得病，沒驗出）：1
 - 偽陽性（沒病，誤判陽性）：495
 - 真陰性（沒病，驗陰）：9405
- 驗出陽性者共 594 人，其中真得病只 99 人
 $P(\text{病} | \text{陽}) = 99/594 \approx 17\%$

圖 4-3-4：10000 人受檢的自然頻率方塊圖（每格 1 人）。真陽性 99 人、偽陽性 495 人、真陰性 9405 人、偽陰性 1 人。驗出陽性者共 594 人，真得病者只有 99 人，故 $P(\text{病} | \text{陽}) = 99/594 \approx 17\%$ 。

注意：不要把「敏感度」當成「得病機率」。99% 是 $P(T | S)$ （得病者中陽性的比例，是檢驗本身的性質）；受檢者真正在意的是 $P(S | T)$ （陽性者中真得病的比例）。兩者一個是「病 → 陽」、一個是「陽 → 病」，方向相反，數值可以差很多。把這兩個搞混，稱為**基本比率謬誤（base rate fallacy）**——忽略了盛行率這個基本比率，是連受過訓練的醫師都常犯的錯誤。

延伸閱讀 | 貝氏定理在哲學上仍有兩派（但不影響高中計算）

貝氏定理本身是數學恆等式，由乘法公式移項而得，必然成立，沒有任何爭議。有不同學派的是它背後的機率哲學：

- **頻率學派 (frequentist)**：機率只能談「可重複試驗的相對次數」，反對把「一個人是否得病」這種一次性命題賦予機率，因此對「主觀先驗」抱持保留。
- **貝氏學派 (Bayesian)**：機率就是「相信程度」，可以對任何命題給先驗，再用貝氏定理隨證據更新。現代機器學習、醫療決策、垃圾郵件過濾大多採貝氏思路。

這是統計學的方法論之爭，至今並存，各有適用場景。但無論站哪一派，上面篩檢例子的算術結果完全相同。此外要說明：篩檢得到約 16.7% 並不代表這種檢驗沒用——它把得病機率從 1% 提升到 16.7%（約十幾倍），足以篩出該做進一步確診檢查的對象。篩檢的定位本就是「初篩」而非「確診」。

D. 先驗到後驗：機率是會更新的判斷

回頭看 4-3-1 的主觀機率。貝氏定理給了主觀機率一個**動態的生命**：先憑經驗給一個**先驗**（相信程度），每當有**新證據**進來，就用貝氏定理把它更新成**後驗**；後驗又可以當成下一輪的先驗，繼續被新證據修正。這就是現代**貝氏統計 (Bayesian statistics)** 的核心精神，也是垃圾郵件過濾、醫療診斷、機器學習裡無所不在的思路。

由此把全章串成一條主線：古典機率告訴你還沒看資料前該信多少（先驗），條件機率提供「已知一個情報後如何更新」的工具，貝氏定理則告訴你看到資料後該改成多少（後驗）。**機率不是冰冷的數字，而是會隨證據更新的判斷。**

4-3-4 本章重點整理

一頁複習（公式與關鍵結論）

- **兩種機率**：客觀（古典＝對稱等可能、頻率＝大量試驗的相對次數穩定值）／主觀（個人相信程度，仍須服從機率公理）。
- **機率公理**： $0 \leq P \leq 1$ 、 $P(S) = 1$ 、互斥可加； $P(A^c) = 1 - P(A)$ ； $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ 。
- **條件機率**： $P(A | B) = \frac{P(A \cap B)}{P(B)}$ （樣本空間縮小成 B ）；一般 $P(A | B) \neq P(B | A)$ 。
- **乘法公式**： $P(A \cap B) = P(B)P(A | B) = P(A)P(B | A)$ （連抽、不放回必用）。
- **獨立**： $P(A \cap B) = P(A)P(B) \iff P(A | B) = P(A)$ （互不影響；放回 $\Rightarrow$ 獨立）。
- **獨立 $\neq$ 互斥**：互斥是 $A \cap B = \emptyset$ （不會同時發生）；兩個正機率事件若互斥，必然不獨立。
- **全機率公式**： $P(A) = \sum_i P(B_i)P(A | B_i)$ （先依來源分類，再加總）。

- 貝氏定理： $P(A | D) = \frac{P(A)P(D | A)}{P(D)}$ ；先驗 $\rightarrow$ 後驗。篩檢陽性 $\neq$ 真得病：盛行率低時偽陽性壓垮真陽性（基本比率謬誤）。